

Anomaly Explainer

Détection et Explication des Fraudes Bancaires avec Auto-encodeur et LLM

Résumé du projet

La détection de transactions bancaires frauduleuses est un enjeu majeur pour les institutions financières. Les modèles classiques sont efficaces pour repérer des anomalies, mais ils ne fournissent généralement pas d'explications claires sur pourquoi une transaction semble suspecte. Ce projet propose une approche hybride combinant un auto-encodeur pour la détection automatique d'anomalies et un Large Language Model (LLM) pour l'explication naturelle et compréhensible des comportements suspects.

Le résultat est un système intelligent capable non seulement de détecter les fraudes, mais aussi de justifier ses décisions de manière transparente pour les analystes ou les auditeurs.

1. Introduction

Les fraudes par carte bancaire représentent un problème critique dans le secteur financier. La plupart des transactions étant légitimes, les données de fraude sont très déséquilibrées, rendant difficiles l'usage de modèles supervisés traditionnels.

Les auto-encodeurs constituent une solution idéale, car ils apprennent la structure des transactions normales et signalent automatiquement toute transaction trop différente.

Cependant, un auto-encodeur ne fournit qu'un score numérique, souvent difficile à interpréter.

Pour combler cette lacune, ce projet intègre un LLM chargé de générer des explications naturelles, détaillées et pertinentes sur les anomalies détectées.

2. Objectifs

Les objectifs principaux du projet sont :

- Détecter automatiquement des anomalies dans des transactions bancaires en utilisant un auto-encodeur entraîné uniquement sur des transactions normales.
- Fournir une explication claire, textuelle et contextualisée en s'appuyant sur un modèle de langage (LLM).
- Améliorer la transparence et la confiance dans les systèmes automatiques de détection de fraude.
- Créer un pipeline complet incluant préparation des données, entraînement du modèle, détection, génération d'explications et interface utilisateur.

3. Présentation du Dataset

Le projet utilise le dataset public Credit Card Fraud Detection disponible sur Kaggle :

<https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>

Il contient 284 807 transactions, dont seulement 492 frauduleuses ($\approx 0,17\%$).

Chaque transaction comporte :

- 28 variables anonymisées (issues d'une transformation PCA),
- le temps écoulé depuis la première opération,
- le montant de la transaction,
- un label indiquant si la transaction est frauduleuse (utilisé uniquement pour évaluer les performances).

Ce dataset est largement utilisé en recherche pour la détection d'anomalies grâce à son déséquilibre extrême et à la difficulté de ses patterns.

4. Méthodologie

La méthodologie repose sur deux modules complémentaires :

- un modèle d'auto-encodeur,
- un module d'explication basé sur un LLM.

4.1. Transformer Auto-encodeur pour la détection d'anomalies. :

Dans cette étude, nous remplaçons l'auto-encodeur classique par un Transformer Auto-Encoder, une architecture moderne basée sur le mécanisme d'attention (attention mechanism).

Le modèle fonctionne toujours selon le principe fondamental d'un auto-encodeur mais avec des composants plus puissants :

- Transformer Encoder : analyse les relations complexes entre les différentes variables d'une transaction grâce à l'attention multi-têtes.
- Espace latent : vecteur compact représentant la transaction.
- Transformer Decoder : tente de reconstruire la transaction originale à partir de cet embedding.

Le mécanisme d'attention permet au modèle de pondérer l'importance de chaque feature et d'apprendre des interactions non linéaires complexes, ce qui améliore la qualité de reconstruction et donc la détection d'anomalies.

Une transaction est considérée comme anormale si l'erreur de reconstruction dépasse un seuil défini statistiquement. **Étapes :**

1. Normalisation des données
2. Entraînement de l'auto-encodeur uniquement sur les transactions normales
3. Calcul de l'erreur de reconstruction pour chaque transaction
4. Définition d'un seuil : si l'erreur dépasse ce seuil, la transaction est considérée comme anormale

Logique :

Une transaction frauduleuse possède des patterns que le modèle n'a jamais appris. Elle sera donc mal reconstruite, par conséquent l'erreur augmente et l'anomalie est détectée.

4.2. Explainer LLM

Pour la partie explicative, nous utilisons un LLM local exécuté via Ollama. Contrairement aux solutions cloud (OpenAI, Mistral, etc.), Ollama permet d'exécuter un modèle de langage entièrement en local, sans envoyer de données sur Internet.

Pour chaque transaction détectée comme suspecte, un LLM analyse les informations suivantes :

- valeurs originales,
- reconstruction du modèle,
- erreur par attribut,
- score de sévérité de l'anomalie.

Le LLM génère ensuite une explication comprenant :

- les attributs responsables de l'anomalie,
- une interprétation du comportement suspect,
- un niveau de risque estimé,
- des suggestions d'analyse pour un humain

5. Architecture du système

L'architecture globale se compose de quatre modules principaux :

1. Prétraitement des données : Normalisation et séparation des transactions normales et frauduleuses.
2. Auto-encodeur : Apprentissage de la structure des transactions normales.

3. Moteur de détection : calcul de l'erreur, comparaison au seuil, classification normale/anormale.
4. LLM Explainer : Génération d'une explication interprétable par des humains.

6. Résultats attendus

Le système devrait permettre :

- une forte capacité à identifier les transactions frauduleuses grâce à une reconstruction error nettement plus élevée pour celles-ci.
- une réduction drastique du nombre de faux positifs (grâce à un seuil adapté).
- une compréhension plus transparente des raisons pour lesquelles une transaction est classée comme suspecte.
- une interface réutilisable par des analystes métiers capable de justifier chaque détection.